TA4

lunes, 20 de octubre de 2025 10:27

Problema 1: PCA y SVD aplicado a señales biomédicas

En sistemas de monitoreo clínico es común registrar múltiples señales fisiológicas simultáneamente: frecuencia cardíaca, SpO_2, presión arterial, temperatura, entre otras. Esto genera datos de alta dimensión, donde algunas variables pueden contener información repetida o correlacionada.

La Descomposición en Valores Singulares (SVD) permite encontrar una representación compacta de esos datos en un espacio de menor dimensión, idea directamente relacionada con PCA.

Considere la matriz X, donde cada fila representa un paciente y cada columna una señal fisiológica registrada durante una prueba de esfuerzo:

$$X = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 3 & 3 & 0 & 0 \\ 4 & 4 & 0 & 0 \\ 0 & 0 & 4 & 4 \\ 0 & 0 & 5 & 5 \\ 0 & 0 & 2 & 2 \end{bmatrix}$$

Los pacientes 1–3 presentan un patrón predominante en las señales 1 y 2, mientras que los pacientes 4–6 presentan un patrón predominante en las señales 3 y 4.

Se sabe que la SVD reducida de X permite representar los datos usando dos componentes principales.

a) Explique con sus propias palabras qué representa aplicar PCA/SVD a este conjunto de señales biomédicas.

Significa reducir la cantidad de variables/dimensiones/columnas requeridas para entrenar un modelo de machine learning; debido a que existe información redundante

b) ¿Por qué este dataset presenta redundancia en sus variables? Relacione su respuesta con las columnas de X.

Porque existen 2 pares de columnas que tienen los mismos resultados; es decir, dos pares de sensores que otorgan la misma información (redundancia)

c) Suponga que los dos valores singulares no nulos son:

$$\sigma_1 = 7.35, \qquad \sigma_2 = 5.10$$

La varianza explicada por cada componente es proporcional a σ_i^2. Calcule el porcentaje de varianza explicado por cada componente principal.

$$\sigma_{total} = \sigma_1^2 + \sigma_2^2 = 7{,}35^2 + 5{,}10^2 = 80{,}0325$$

$$\Rightarrow \% \sigma_1 = \frac{7{,}35^2}{80{,}0325} = 0{,}67501 \rightarrow \underline{67{,}5\%}$$

$$\Rightarrow \% \sigma_2 = \frac{5{,}10^2}{80{,}0325} = 0{,}32499 \rightarrow \underline{32{,}5\%}$$

d) Llega un nuevo paciente, Lucía, con el siguiente perfil fisiológico:

$$x_{Lucía} = \begin{bmatrix} 3 & 3 & 0 & 0 \end{bmatrix}$$

Sin hacer una proyección numérica completa, indique con qué grupo de pacientes se asocia más Lucía en el espacio reducido: pacientes 1–3 o pacientes 4–6. Justifique.

Se asocia más con los 3 primeros pacientes (1-3) debido a que tiene el valor 3 en los dos primeras columnas y el valor "3" solo existe en esas columnas

e) En el Challenge 5 se aplicó `StandardScaler` antes de PCA. Explique en qué casos es necesario estandarizar antes de aplicar PCA/SVD. ¿Qué problema podría surgir en un dataset biomédico real si se omite este paso?

- Es necesario aplicar cuando se tienen variables con diferentes unidades físicas y/o cuando sus valores son muy grandes entre sí
- De no hacerse, debido a la escala, el PCA estará sesgado debido a que es sensible a valores grandes

Problema 2. K-means, centroides y su interpretación biomédica

K-means es ampliamente utilizado en reconocimiento de patrones biomédicos para agrupar señales, pacientes o características sin etiquetas. Por ejemplo, puede emplearse para agrupar pacientes con perfiles cardiometabólicos similares o tumores con características morfológicas parecidas.

K-means busca dividir los datos en K grupos, minimizando la distancia de cada punto al centroide de su cluster.

La función objetivo de K-means es:

$$J = \sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

donde:

- C_k es el conjunto de puntos asignados al cluster k,
- μ_k es el centroide del cluster k.

Se pide:

a) Explique con sus propias palabras qué significa minimizar J.

Significa hacer o buscar que los puntos de información estén lo más cerca posible uno del otro; es decir, tener la mínima distancia euclidiana entre sí

b) ¿Qué representa el centroide μ_k en un problema biomédico? Dé un ejemplo.

Representa el principal valor, característico y/o promedio que definen a un grupo/cluster. Por ejemplo, en diabetes se tiene un valor de glucosa en sangre superior a lo normal. El centroide sería aquel valor de glucosa en sangre central, a cuyo alrededor, cualquier otro valor tmb indica diabetes

c) Explique por qué K-means puede ser sensible a la inicialización de los centroides.

Porque el algoritmo optimiza localmente. Este toma los puntos cercanos alrededor de un centro definido, el centroide.

d) K-means garantiza encontrar el mínimo global de J? Justifique.

No, porque el algoritmo busca el óptimo local; de ahí que el resultado sea sensible de la posición inicial del centroide. Cada cluster buscará su propio punto óptimo, pero el conjunto no necesariamente será el óptimo global.

e) Explique cómo `KMeans(n_init=10)` ayuda a reducir el problema de la

e) Explique como `KMeans(n_init=10)` ayuda a reducir el problema de la inicialización.

Porque se indica al programa de repetir 10 veces el mismo procedimiento, para tomar el valor con el menor J; lo cual sí puede ayudar a encontrar un mínimo global

f) En el Challenge 5 se aplicó K-means sobre el espacio PCA reducido del dataset Breast Cancer Wisconsin. Explique por qué puede tener sentido interpretar los centroides como perfiles morfológicos promedio de cada grupo tumoral.

Porque se está resumiendo las principales características de la patología en un punto que representa a la mayoría de pacientes con esa enfermedad

g) Mencione dos limitaciones de K-means en problemas biomédicos reales.

- Sensibilidad a valores atípicos, es normal encontrar casos extremos y/o atípicos; esto se traduce en un valor alto para una o varias variables, lo que desplaza el promedio y el centroide
- Clusters esféricos: El algoritmo asume que los grupos tienen formas circulares y densidades similares. Este es un patrón que no aplica en medicina, por lo que el algoritmo cometerá errores de clasificación