

## Tarea Complementaria

**Problema 1.** En el desarrollo de sistemas de apoyo clínico basados en machine learning, elegir correctamente los hiperparámetros de un modelo es tan importante como elegir el modelo en sí. Una mala evaluación puede llevar a un sistema que funciona bien en laboratorio, pero falla con pacientes reales.

## Parte A — Estimación del error de generalización

Sea:

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$$

un dataset de  $N = 120$  pacientes con diagnóstico de diabetes. Se desea estimar el error de generalización de un clasificador SVM.

a) Se aplica K-fold cross-validation con  $K = 5$ . Describa el procedimiento paso a paso:

- cómo se dividen los datos,
- cuántos modelos se entrenan,
- sobre qué subconjunto se evalúa cada modelo,
- cómo se calcula el error promedio final,
- cuántos pacientes hay en entrenamiento y evaluación en cada fold.

• Con  $k=5$ , tenemos 5 grupos/Folds de 24 pacientes cada uno

• En total son 5 modelos, 1 por Fold

• Hay 4 subconjuntos de entrenamiento y 1 de evaluación, el que fue excluido del Fold

• Tras calcular el error de cada Fold tras el entrenamiento, simplemente se promedian los errores de cada fold

b) El error observado en cada fold es:

$$e_1 = 0.12, \quad e_2 = 0.15, \quad e_3 = 0.11, \quad e_4 = 0.18, \quad e_5 = 0.14$$

Calcule el error estimado de validación cruzada:

$$\hat{e}_{CV} = \frac{1}{K} \sum_{k=1}^K e_k$$

y su desviación estándar:

$$s_{CV} = \sqrt{\frac{1}{K-1} \sum_{k=1}^K (e_k - \hat{e}_{CV})^2}$$

Reporte el resultado como:

$$\hat{e}_{CV} \pm s_{CV}$$

| => Error | Acumulado | Desviación | Desv <sup>2</sup>  | Des <sup>2</sup> Acumulada                           |
|----------|-----------|------------|--------------------|------------------------------------------------------|
| 0,12     | 0,12      | -0,02      | $4 \cdot 10^{-4}$  | $4 \cdot 10^{-4}$                                    |
| 0,15     | 0,27      | 0,01       | $1 \cdot 10^{-4}$  | $5 \cdot 10^{-4}$                                    |
| 0,11     | 0,38      | -0,03      | $9 \cdot 10^{-4}$  | $14 \cdot 10^{-4}$                                   |
| 0,18     | 0,56      | 0,04       | $16 \cdot 10^{-4}$ | $30 \cdot 10^{-4}$                                   |
| 0,14     | 0,70      | 0          | 0                  | $30 \cdot 10^{-4}$                                   |
| Promedio | 0,14      | SCV        |                    | $\sqrt{7,5 \cdot 10^{-4}}$<br>$2,7386 \cdot 10^{-2}$ |

Promedio | 0,14 | SCV |  $\sqrt{\frac{7,5 \cdot 10^{-4}}{2,7386 \cdot 10^{-2}}}$

•  $\approx 0,14 \pm 0,03$  ✓

Entonces, el modelo tiene un 14% de equivocarse con una sensibilidad del 80%, por lo que es robusto el modelo

c) Se propone la siguiente estrategia:

- Entrenar con todo el dataset  $\mathcal{D}$ .
- Aplicar 5-fold CV para estimar el error.
- Reportar el modelo como listo para despliegue clínico.

Identifique el problema metodológico de esta estrategia. Explique cómo debería corregirse usando un conjunto de test externo. Describa el esquema correcto de división de datos.

El error es entrenar con todo el dataset, esto provoca data leakage; por lo que el modelo tendrá resultados altos artificiales, por que se usa la data que ya aprendió para validar

#### Parte B — Búsqueda de hiperparámetros

Se entrena un SVM-RBF sobre un dataset de clasificación de arritmias. Los hiperparámetros a optimizar son:

$$C \in \{0,1,10,100\} \quad 4$$

$$\gamma \in \{0,001,0,01,0,1,1\} \quad 4$$

d) Si se realiza Grid Search con 5-fold CV, ¿cuántas evaluaciones de modelos se realizan en total? Muestre el cálculo.

Se tiene 4 valores por cada hiperparámetro; entonces se tiene  $4 \times 4 = 16$  combinaciones.

Dado a que habrá 5 Folds en la que se hará validación en cada modelo; entonces habrá  $5 \times 16 = 80$  evaluaciones en total

e) Los resultados de accuracy promedio en validación cruzada para algunas combinaciones son:

| C   | $\gamma$ | CV accuracy | CV std |
|-----|----------|-------------|--------|
| 0.1 | 0.001    | 0.71        | 0.03   |
| 1   | 0.01     | 0.86        | 0.02   |
| 10  | 0.1      | 0.93        | 0.04   |
| 100 | 1        | 0.94        | 0.08   |

Se elige  $C = 100$ ,  $\gamma = 1$  porque tiene la mayor accuracy.

Explique por qué esta elección podría ser incorrecta. ¿Qué criterio más robusto aplicaría para elegir entre  $C = 10$  y  $C = 100$ ?

$C = 100$  y  $\gamma = 1$  no es la opción más óptima, tiene un 8% de std, sensibilidad. La mejor opción es  $C = 10$  y  $\gamma = 0,1$  debido a que tiene 4% de std, es el doble de robusto con una mínima caída del accuracy

#### Problema 2. Pipelines y despliegue de modelos clínicos

En ingeniería biomédica, un modelo de machine learning no termina cuando se obtiene una buena accuracy en el notebook. El modelo debe ser reproducible, mantenible y desplegable en un entorno clínico real.

## Problema 2. Pipelines y despliegue de modelos clínicos

En ingeniería biomédica, un modelo de machine learning no termina cuando se obtiene una buena accuracy en el notebook. El modelo debe ser reproducible, mantenible y desplegable en un entorno clínico real.

Se desea construir un sistema de clasificación de riesgo cardíaco que procese datos crudos de pacientes y entregue una predicción. El pipeline debe incluir:

- imputación de valores faltantes,
- estandarización,
- selección de features,
- clasificador Random Forest.

### Parte A — Diseño de pipeline

1. **Limpieza:** Eliminar datos vacíos o valores imposibles con la variable a la que pertenecen, a todo el D
2. **Aplicar train/test split 80/20**, para separar la data de validación de la data de entrenamiento
3. **Estandarización:** Ajustar la escala y la desviación estándar para evitar sesgos o mayor peso injustificado sobre variables. Mediante z-score solo al D-train
4. **Selección de Features:** Elegir las variables más significativas para reducir la cantidad de dimensiones. Se eligen 10 variables más significativas, solo D-train
5. **Train/Tests:** Entrenar y validar el modelo

b) Considere el siguiente pipeline incorrecto aplicado sobre un dataset biomédico:

```
Paso 1: Imputar mediana de Cholesterol sobre TODO el dataset
Paso 2: Aplicar StandardScaler sobre TODO el dataset
Paso 3: Train/test split 80/20
Paso 4: Entrenar Random Forest sobre X_train
Paso 5: Evaluar sobre X_test
```

No se debe estandarizar toda la data, porque se da **data leakage**, parte de la info del test se cuele y usa para escalar la información

### Parte B — Despliegue con Streamlit

Se ha entrenado y validado un modelo Random Forest para clasificar riesgo cardíaco. El siguiente paso es desplegarlo como una aplicación web clínica usando Streamlit.

c) Describa la arquitectura mínima de una aplicación Streamlit para este modelo. Su respuesta debe especificar:

- qué archivos se necesitan,
- cómo se carga el modelo serializado,
- cómo ingresa los datos el usuario,
- cómo se realiza la predicción,
- cómo se muestra el resultado.

No es necesario escribir código completo; una descripción estructurada es suficiente.

Archivos:

- program.py
- ML-model.py
- dependencias.txt
- README.md

- **Modelo:** El modelo entrenado se puede guardar con `dump()` y luego cargar con `load()`
- **Input:** En el Front End de la app existen widgets que permiten introducir elementos como el valor de ciertas variables

• **Output:** Mediante un botón para predecir, se puede usar los comandos `predict()` para obtener la predicción y el error, si se desea, para ser mostrado en la interfaz de Streamlit

d) Un médico introduce los datos de un nuevo paciente y el modelo devuelve:

Alto riesgo: 87% de probabilidad

Identifique y discuta tres limitaciones reales que el médico debería conocer antes de tomar una decisión clínica basada en esta predicción. Puede relacionarlo con:

- cambio de distribución. ✓
- sesgo del dataset. ✓
- incertidumbre del modelo.
- mala calibración de probabilidades,
- data leakage previo,
- falta de validación externa.

- El modelo pudo haber sido entrenado con data de una población diferente a la que se intenta predecir; por lo que la probabilidad puede ser menor. *Distribución diferente*
- Si el modelo fue entrenado con data predominante de una población específica; como muchos hombres y pocas mujeres; el modelo pierde precisión a predecir casos de mujeres por el *sesgo* en su entrenamiento
- Puede que el modelo solo haya sido evaluado con información del dataset de entrenamiento y no con información real del entorno en el que se usa

e) El jefe de servicio pregunta:

¿Por qué el modelo predice alto riesgo para este paciente?

El Random Forest no es directamente interpretable como una regla clínica simple. Mencione dos estrategias que el ingeniero biomédico podría usar para responder esta pregunta y explique brevemente en qué consiste cada una.

1º *Análisis de importancia de variables*, se puede calcular cuánto influencia cada variable en la decisión final del modelo. En el modelo, al observar cuántas veces aparece una variable, se puede explicar parte de la decisión

2º *Mediante SHAP*: Permite calcular la influencia de las variables en predicciones individuales mediante teoría de juegos. Este analiza cómo varía la respuesta al variar las variables